本科毕业设计（论文）

个人健康管理智能体的设计与实现

Design and Implementation of a Personal Health Management Agent

院　　系：计算机科学与技术学院

专业班级：计算机科学与技术 2105 班

姓　　名：袁立沛

学　　号：U202217212

指导教师：邱德红

2026 年 5 月 8 日

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

学生签名：

日　　期：　　年　　月　　日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省优秀学士学位论文评选将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

1、保密 □，在_____年解密后适用本授权书。

2、不保密 □。

（请在以上相应方框内打”√”）

学生签名：

指导教师签名：

日　　期：　　年　　月　　日

摘　　要

我国高血压患病人数已超过 2.45 亿，但知晓率、治疗率和控制率分别仅为 51.6%、45.8% 和 16.8%。家庭自测血压虽已逐步普及，患者仍普遍面临”只测不看、只看不懂”的困境——手动誊写读数繁琐易错，现有管理应用缺乏个性化趋势解读，网络上的健康信息真假难辨。

本文设计并实现了一款面向家庭的个人健康管理智能体 HealthAgent，围绕血压计屏幕图像识别、健康数据趋势分析和安全合规的大模型健康问诊三条主线展开。系统后端基于 Python FastAPI 框架与 SQLite 数据库，前端使用 React 18 与 TypeScript，通过 Ant Design 5 和 ECharts 构建用户界面。

在 OCR 识别方面，本文提出了一种双通路协同方案：以百度云数字 OCR 作为主通路保证速度，以通义千问视觉大模型（VLM）作为兜底通路补充主通路未能识别的字段。在 4 张真实血压计屏幕样本的测试中，该方案取得了 75.0% 的字段级准确率，相较纯 PaddleOCR 方案（0%）和纯百度云方案（8.3%）有显著提升。在安全问诊方面，本文构建了包含 12 篇医学文档的向量知识库，设计了嵌入用户近 14 天血压数据的个性化 Prompt 模板和六条安全红线，并通过规则式自动评测脚本验证了引用标注率、免责声明率和剂量安全率三项指标均达到 100%。

系统建立了覆盖单元测试、集成测试和端到端测试的多层次测试体系，86 项后端测试用例全部通过，代码覆盖率达到 82%。

关键词：健康管理智能体；OCR 图像识别；大语言模型；检索增强生成；时序预测

Abstract

Hypertension affects over 245 million people in China, yet awareness, treatment, and control rates remain low at 51.6%, 45.8%, and 16.8% respectively. While home blood pressure monitoring has become common, patients often struggle to interpret their readings and lack access to reliable, personalized health guidance.

This paper presents HealthAgent, a personal health management agent designed for home use. The system integrates three core capabilities: OCR-based recognition of blood pressure monitor readings, health data trend analysis, and safety-compliant LLM-powered health consultation. The backend is built with Python FastAPI and SQLite, while the frontend uses React 18, TypeScript, Ant Design 5, and ECharts.

A dual-pathway OCR architecture is proposed, combining Baidu Cloud numeric OCR as the primary pathway with Tongyi Qianwen VLM as a fallback. On four real-world blood pressure monitor images, this approach achieves 75.0% field-level accuracy, a substantial improvement over pure PaddleOCR (0%) and pure Baidu Cloud OCR (8.3%). For the consultation module, a vector knowledge base of 12 medical documents was constructed, with personalized prompt templates incorporating users' 14-day blood pressure data and six safety constraints. An automated rule-based evaluation script confirmed 100% compliance on citation, disclaimer, and dosage safety metrics.

The system includes a multi-level testing framework with 86 backend test cases all passing at 82% code coverage.

Keywords: Health Management Agent; OCR Image Recognition; Large Language Model; Retrieval-Augmented Generation; Time Series Prediction

目　　录

目录

学位论文原创性声明 **1**

学位论文版权使用授权书 **2**

摘要 **3**

Abstract **4**

目录 **5**

1 绪论 **7**
1.1 研究背景与意义 7
1.2 国内外研究现状 7
1.2.1 医疗设备屏幕 OCR 7
1.2.2 健康数据趋势分析 8
1.2.3 大模型在医疗领域的应用 9
1.3 本文的主要工作 10
1.4 论文组织结构 11

2 相关技术 **12**
2.1 光学字符识别技术 12
2.2 大语言模型与 RAG 12
2.3 时序数据分析方法 13
2.4 系统实现技术栈 13

3 需求分析与系统设计 **15**
3.1 功能需求 15
3.2 目标用户与使用场景 15
3.3 非功能需求 16
3.4 系统架构 16
3.5 数据库设计 17
3.6 安全设计 18

4 关键模块实现 **19**
4.1 双通路 OCR 血压计图像识别 19
4.1.1 整体流水线 19
4.1.2 方案对比实验 20

4.1.3 人机协同录入界面 21
4.2 健康数据管理与趋势预测 21
4.2.1 数据管理与用户隔离 21
4.2.2 统计聚合 21
4.2.3 自适应窗口趋势判定 21
4.2.4 前端看板 22
4.3 RAG 大模型健康问诊 22
4.3.1 知识库构建 22
4.3.2 语义检索 22
4.3.3 安全 Prompt 设计 23
4.3.4 SSE 流式问答 23
4.3.5 自动评测 23

5 系统测试与评测 25
5.1 测试策略 25
5.2 后端测试 25
5.3 前端测试与类型检查 25
5.4 全链路端到端测试 25
5.5 RAG 问诊评测 26
5.6 性能基准 27
5.7 安全测试 27
5.8 验收结论 27

6 结论与展望 28
6.1 工作总结 28
6.2 存在的不足 28
6.3 未来展望 29

参考文献 30

附录 32

致谢 34

1 绪论

1.1 研究背景与意义

过去四十年间，随着经济快速发展和生活方式转变，慢性非传染性疾病已取代传染病成为威胁我国居民健康的首要因素。据《中国心血管健康与疾病报告 2023》统计，我国 18 岁以上人群高血压患病率约为 27.9%——相当于每 4 个成年人中就有 1 人患有高血压，总患病人数超过 2.45 亿，且呈现明显的年轻化趋势。然而，与高患病率形成鲜明对比的是极低控制水平：知晓率仅 51.6%，治疗率 45.8%，控制率更是低至 16.8%。大量研究表明，血压管理是心脑血管疾病最有效的可干预手段——收缩压每降低 10 mmHg，主要心血管事件风险降低 20%，卒中风险降低 27%。

电子血压计的普及使家庭自测成为可能，但测量之后的环节仍是断链的。大多数用户的流程是：测量 → 看一眼读数 → 凭记忆或随手记在纸上 → 过几天就忘了。对于老年用户来说，即便有心记录，视力衰退和手指灵活性下降也让手动誊写成为负担。部分高端血压计支持蓝牙同步到品牌 App，但各品牌数据互不联通，用户如果换了设备，历史数据就断了。更深层的问题在于数据分析的缺位——现有管理应用大多只能画出血压曲线，但对”这条曲线意味着什么”给不出答案。用户不知道某次偏高读数是否需要警惕，也不清楚近期的生活方式调整是否真的在起作用。

健康咨询的可及性是另一个现实难题。互联网上的高血压科普鱼龙混杂，患者很容易被商业推广或伪科学内容误导。而去医院咨询医生，挂号和排队的时间成本让很多人望而却步，这在农村和偏远地区尤为突出。

近两年来，大语言模型和检索增强生成技术的成熟为解决上述问题提供了新思路。OCR 技术可以让用户拍照即完成数据录入；RAG 技术通过将大模型”锚定”在可验证的医学知识上，有效缓解了幻觉问题；而流式输出让对话体验接近真人交流。将这些技术有机整合，构建一款面向普通家庭、操作简单但内核专业的健康管理工具，是一件有实际意义的工作。

基于以上背景，本文设计并实现了 HealthAgent——一款围绕”拍照录入 → 趋势分析 → 智能问诊”三大环节的个人健康管理智能体。

1.2 国内外研究现状

1.2.1 医疗设备屏幕 OCR

光学字符识别技术的发展可以追溯到 20 世纪 60 年代。早期 OCR 系统依赖于模板匹配和人工设计的几何特征，对字体、字号、排列方向都有严格要求。20 世纪 90 年代以后，随着统计机器学习方法的引入，OCR 的适应性有了质的提升——Tesseract 引擎自 1985 年由 HP 实验室启动研发，历经三次架构重构，在 2006 年开源后成为使用最广泛的通用 OCR 引擎之一。进入深度学习时代，基于 CNN 和 CTC（Connectionist Temporal Classification）的文本识别方法大幅提升了场景文本识别的准确率，CRNN+CTC 架构一度成为行业标配。2020 年以来，百度开源的 PaddleOCR

系列（PP-OCR、PP-OCRv2/v3/v4）凭借轻量化设计在移动端部署场景中表现出色，其 v4 版本在通用中英文场景下达到了 95% 以上的识别率。

然而，将通用 OCR 技术应用于电子血压计屏幕识别，仍然面临几个特有的困难。首先是显示介质的特殊性。家用电子血压计普遍采用七段数码管或低分辨率 LCD 液晶屏，数字字形与通用 OCR 训练集中的印刷体差异很大——数码管的"1" 可能被识别为"l"，"8" 可能被识别为"0" 或"B"；LCD 屏上"6" 和"5" 的笔画断裂也会导致系统性误识别。我们在实测中验证了这一点：PaddleOCR PP-OCRv4 在 4 张血压计屏幕样本上的字段级准确率为 0%，因为模型完全没有见过这类字形。其次是拍摄条件的不可控。用户可能在任何光照角度、任何距离下拍摄，反光、阴影、模糊都会严重影响识别效果——这与文档扫描场景下的受控环境完全不同。第三是字段归属问题——屏幕上同时存在收缩压、舒张压、心率以及时间、电量图标、记忆编号等辅助信息，需要准确区分哪些数字是血压读数、哪些是无关信息。这些问题单独拆开都不算难，但叠加在一起就构成了一个典型的" 小样本 + 复杂场景" 工程难题。

针对这些困难，现有方案大致分为两路。传统 OCR 路线（如 Tesseract、PaddleOCR）速度快、成本低，但对非标准字体的泛化能力不足——Tesseract 的 LSTM 识别层虽然通过大量合成数据训练获得了不错的字体适应力，但在七段数码管这类与训练分布差异过大的场景下仍然失效。多模态视觉大模型路线（如 GPT-4V、通义千问 VL、Gemini Pro Vision）通过语义理解大幅提升了鲁棒性：模型不仅" 看" 到了数字形状，还能够利用屏幕布局、字段间语义关系等上下文信息做出判断。但代价也很明显——单次调用需要 2–3 秒，且 API 费用通常是专用 OCR 的数十倍；对于" 每次测量都要识别" 的高频场景来说，成本累积不可忽视。

本文据此提出了一个折中思路：以专用数字 OCR 作为主通路处理常规情况，仅在主通路产出不完整时触发 VLM 兜底。这样既保留了专用 OCR 的速度和成本优势，又借助 VLM 的语义能力覆盖了困难样本。类似的" 级联 + 兜底" 策略在工业部署中并不鲜见，但将其应用于家用医疗设备屏幕识别这一细分场景，并给出定量的对比实验数据，是本课题的一个特色贡献。

1.2.2 健康数据趋势分析

面向个人的健康数据管理工具已形成较丰富的产品生态。在国际市场上，Apple Health 通过 HealthKit 框架聚合来自 iPhone、Apple Watch 及第三方设备的数据，覆盖心率、血压、血氧、睡眠等数十项指标，但其设计重心在数据聚合而非专科分析——它能告诉你" 上个月平均收缩压是 135 mmHg"，但不会进一步解释这个数值意味着什么。Google Fit 则在 2022 年改版后引入世界卫生组织和美国心脏协会的运动建议作为活动目标参考，但在慢病管理的深度上同样有限。硬件厂商方面，Omron Connect 配合欧姆龙蓝牙血压计使用，支持测量数据的自动同步和基础图表展示，但数据锁定在品牌生态内；Withings Health Mate 走的是跨品类路线（血压计 + 体重秤 + 手表），在生活干预建议的细节上做得更细致一些，但中文支持和国内本地化程度不足。

国内市场上，华为运动健康和小米健康分别依托各自的穿戴设备生态，用户基数

庞大。华为运动健康在血压管理方面与多家医疗机构合作开展高血压管理研究，部分型号手表已支持腕式血压测量和血压健康研究计划，在数据采集端实现了”被动测量”的创新——用户不需要专门使用上臂式血压计，日常佩戴手表即可完成数据沉淀。小米健康则通过与小爱同学语音助手的整合降低了老年用户的使用门槛。然而，这些平台的功能定位仍偏向数据采集和简单统计，在数据解读层面大多止步于”本月血压偏高次数：X 次”，缺少针对个人趋势的深度分析，更不提供基于数据的主动健康建议。

在趋势预测方法上，学术界主要探索了三种路径。Prophet 模型由 Facebook 于 2017 年开源，通过将时间序列分解为趋势项、周期项和节假日效应三个可解释组件来做预测，对缺失值和异常值有较好的鲁棒性——这一特性对家庭场景下采样不规律的问题有一定缓解。但 Prophet 的设计假定了至少两个完整周期的数据（通常需要 90 天以上），对于新用户或低频测量用户来说并不适用。LSTM 通过门控机制能够建模复杂的长程时间依赖，在 ICU 患者生命体征预测等医疗时序任务中表现优异；然而，单个家庭用户的自测数据量（通常只有数十到数百条）远不足以训练一个可靠的神经网络——在一个用户的数据上单独训练 LSTM 几乎必然导致过拟合，而在跨用户数据上训练又面临隐私和异质性挑战。ARIMA 作为经典的统计预测方法，理论基础坚实、可解释性强，但对序列的平稳性有严格要求——未经差分处理的血压序列通常不满足平稳条件，而差分操作的选择（阶数、滞后项）又对最终预测结果有显著影响，前处理步骤对非统计背景的开发者而言门槛不低。

这些方法在家庭场景下都面临同一个矛盾——模型需要大量数据才能输出可信预测，而真实的家庭血压监测数据恰恰是稀疏且不规律的。很多用户并非每天测量，新用户更是只有寥寥数条记录。2022 年发表在 JMIR 的一项系统综述分析了 39 项面向消费者的血压管理 App 研究，指出”绝大多数应用仅提供数据可视化，不到 15% 的应用提供了任何形式的预测或趋势分析功能”。这一发现与本课题在项目规划阶段进行的竞品调研结论一致。因此，与其强行输出不可靠的预测，不如在数据不足时诚实告知用户”还需要更多数据”，并给出当前已有的统计信息。本文的趋势判定算法正是基于这一”先无害、再有用”的设计原则。

1.2.3 大模型在医疗领域的应用

大语言模型在医疗健康领域的应用是当前最活跃的研究方向之一。2022 年底 ChatGPT 的发布让公众第一次直观感受到大模型在医学知识问答上的能力，但学术界对医疗 AI 的探索远早于此。2018 年，Google 发布的 BERT 模型在生物医学领域的变体 BioBERT 和 PubMedBERT 通过在海量生物医学文献上继续预训练，在命名实体识别、关系抽取等传统 NLP 任务上取得了当时的最佳成绩，但这些模型缺乏自由文本生成能力，无法直接用于问诊场景。2020 年 GPT-3 的出现标志着生成式 AI 的一个重要拐点——它在零样本和少样本设置下展现出令人意外的泛化能力，其中包含相当可观的医学常识。2023 年 7 月，Google 和 DeepMind 发布了专门针对医疗领域优化的 Med-PaLM 2，在美国医师执照考试（USMLE）类问题上达到了 86.5% 的准确率，与执业医师水平接近。该模型在回答一致性、事实准确性和安全性方面

相比第一代 Med-PaLM 有显著提升，但在真实临床环境中的适用性仍待进一步验证。中文医疗领域也在快速跟进：HuatuoGPT 通过在中文医学对话数据上微调，在医学知识问答和医患对话模拟方面表现突出；BenTsao（本草）模型则侧重于中医药知识和中西医结合方向的问答，填补了通用大模型在中医药领域的知识空白。

然而，多项研究也系统性地指出了三个核心挑战。一是幻觉问题——大模型倾向于以自信的语气生成看似合理但事实错误的内容。在通用对话中，偶尔的事实偏差可能只是带来不便；但在医疗场景下，一个错误的药物剂量建议可能直接危害用户健康。Stanford HAI 在 2024 年发布的医疗 AI 可信度评估报告中指出，即使最先进的模型在医学事实性问题上仍有 3–5% 的错误率，且错误往往出现在模型”最自信”的回答中，这使得仅凭用户主观感受难以甄别。二是知识时效性——模型的知识在训练完成的那一刻就被固化了，无法反映后续发布的临床指南更新。例如 2024 年发布的《中国高血压防治指南》修订版在血压分级标准、药物推荐策略等方面有重要调整，但训练数据截止于 2022 或 2023 年的模型完全不知道这些变化。三是回答的个性化缺失——通用模型的所有训练经验来自”平均人”，它给出的建议是对所有用户都适用的最大公约数，无法结合用户具体的血压历史、年龄、性别、合并症等因素进行差异化调整。一个 25 岁健康年轻人的”正常血压”与一个 70 岁糖尿病患者的”目标血压”可能相差 10–15 mmHg，但通用模型很难在对话中敏锐地做出这种区分。

检索增强生成（Retrieval-Augmented Generation，RAG）由 Lewis 等人于 2020 年在 NeurIPS 上发表，为缓解上述三个问题提供了工程上可行且成本可控的路径。它的核心思路很朴素：在模型生成回答之前，先从外部知识库中检索出与用户问题语义相关的文档片段，将这些片段连同系统指令和用户上下文一起组装成 Prompt，然后才发给大模型。这相当于每次对话前给模型”临时补课”——它不需要在训练阶段记住所有知识，只需要在推理时”阅读”检索到的参考资料。RAG 缓解幻觉的方式是将模型的输出空间约束在可验证的外部知识范围内；解决知识时效性的方式是知识库可以随时更新而无需重新训练模型；而个性化则通过 Prompt 中注入用户专属数据来实现。

相比模型微调，RAG 有几个工程上的明确优势：知识更新只需修改知识库文档而无需重新训练或部署模型；每条事实性陈述可以追溯到知识库中的具体文档来源，这在医疗场景下对可审计性至关重要；部署成本也显著低于维护一个定制微调模型的 GPU 集群。2023 年以来，随着 LangChain 和 LlamaIndex 等 RAG 编排框架的快速成熟，RAG 已在企业知识问答、法律文书检索、医疗咨询辅助等多个领域得到工业级应用。不过，LangChain 等框架的高度抽象也带来了 Prompt 结构不可完全受控、Token 消耗缺乏透明度等问题，因此本系统选择自行编写 RAG 编排逻辑，以换取对安全约束的精确控制。

1.3 本文的主要工作

本文的工作主要包括以下几个方面：

（1）设计并实现了双通路协同的血压计屏幕 OCR 方案。百度云数字 OCR 作为

主通路处理大部分常规情况，通义千问 VLM 在识别结果不完整时补充缺失字段。两个通路在字段级别进行融合，VLM 不覆盖主通路已正确识别的部分。同时，识别结果先回填前端表单供用户确认和校正，而不是直接入库——这种人机协同的闭环设计降低了对 OCR 绝对精度的依赖，也防范了 VLM 可能产生的”合理估计”式错误。

（2）构建了面向医疗安全的个性化 RAG 问诊系统。知识库包含 12 篇医学知识文档，通过 sqlite-vec 扩展实现向量存储与语义检索。Prompt 模板中嵌入了用户近 14 天的血压数据摘要和六条安全红线（禁止剂量建议、禁止确定性诊断、强制引用标注、强制免责声明等），并编写了规则式自动评测脚本对安全指标进行可量化的持续验证。

（3）建立了从数据录入到趋势分析再到可视化看板的完整健康数据管理流水线，包括用户数据隔离、自适应窗口的趋势判定算法，以及基于 ECharts 的双 Y 轴时序看板。

（4）建立了覆盖单元测试、集成测试、端到端测试的分层测试体系。86 个后端测试用例全部通过，代码覆盖率 82%；前端 15 个测试用例全部通过，TypeScript 严格模式零类型错误。

1.4 论文组织结构

本文后续章节安排如下：第二章介绍系统涉及的关键技术及选型依据；第三章进行需求分析和系统架构设计；第四章详细阐述三大核心模块的实现方案；第五章介绍测试策略与评测结果；第六章总结全文并展望未来工作。

2 相关技术

本章介绍 HealthAgent 系统涉及的核心技术。与常规综述不同，本章在介绍每项技术的同时说明针对本系统场景的选型理由，避免技术罗列。

2.1 光学字符识别技术

OCR 的完整流程通常包括图像预处理、文本检测、字符识别和后处理四个阶段。在本系统中，每个阶段都针对血压计屏幕这个特定场景做了适配。

预处理阶段面临的主要问题是用户拍摄条件不可控。我们的处理序列是：先将输入图像（支持 JPG/PNG/WebP）解码为 RGB 数组，然后做长边等比缩放（最长边不超过 1920 像素，兼顾细节保留和计算开销），接着转为灰度图降低数据维度，最后应用 CLAHE（限制对比度自适应直方图均衡化）增强局部对比度。CLAHE 与普通全局直方图均衡化的关键区别在于，它将图像分成 8×8 个小网格，在每个网格内独立均衡化后再通过双线性插值平滑拼接，同时设置对比度限幅（clip limit=2.0）防止噪声被过度放大。这一步对缓解屏幕反光和光照不均的效果比较明显。

文本检测和字符识别在本系统中主要由百度云数字 OCR（numbers 接口）完成。这个接口专为仪表、计数器、液晶屏等数字识别场景做了优化，返回的每个数字附带归一化边界框和置信度分数。选用云端 API 而非本地模型的原因在于：本地部署的通用 OCR 模型（如 PaddleOCR）对七段数码管字形的识别能力几乎为零，而专门针对此场景微调模型又超出了本科毕设的工作量范围。

后处理是本系统 OCR 方案区别于常规 OCR 的关键环节。百度云返回的是一串无序的识别结果，需要从中挑出真正有临床意义的三项数值（收缩压、舒张压、心率），并排除时间戳、电池图标等辅助信息的干扰。我们设计了四步规则式后处理：先按边界框高度过滤掉小字（辅助信息字号通常远小于血压读数），再按 Y 坐标排序利用屏幕的固定物理布局分配字段，然后用生理合理范围做数值校验，最后用”收缩压必须严格大于舒张压”这一医学常识做一致性校验。

2.2 大语言模型与 RAG

大语言模型基于 Transformer 解码器架构，通过在海量文本上的自回归预训练获得了强大的语言理解和生成能力。其生成过程是逐令牌自回归的：每步根据前文计算下一个令牌在整个词表上的条件概率分布，然后按采样策略选取。本系统选用通义千问 qwen-plus 模型，理由比较实际：提供 OpenAI 兼容接口方便后续切换、中文医疗术语覆盖较好、流式输出原生支持、毕设开发阶段有免费额度。

但通用大模型在医疗场景下存在一个致命问题——幻觉。它会用非常自信的语气说出完全错误的内容。在闲聊场景下无伤大雅，但在医疗场景下，一个错误的药物剂量建议可能造成严重后果。

RAG（检索增强生成）的核心思想就是给大模型”发参考资料”：每次对话时，先

从知识库中检索出与用户问题语义相关的文档片段，连同系统指令和用户数据一起组装成 Prompt，再发给大模型。这样，模型的回答被约束在可验证的外部知识范围内，幻觉风险大幅降低。同时，每条事实性陈述都可以追溯到知识库中的具体文档。

我们选择自己编写 RAG 编排逻辑，而非使用 LangChain 等框架。原因在于：Prompt 模板可以完全受控，安全红线的每一条都能精确审计；Token 消耗显式可见，不会出现框架层面的隐性浪费；也不引入额外的第三方依赖。

2.3 时序数据分析方法

在血压趋势判定中，我们采用的是滑动平均加线性回归的轻量组合，而非复杂的时序模型。做出这个选择的出发点是数据现实：家庭血压监测的数据量通常很小——新用户可能只有几条记录，即使老用户也未必每天测量，采样间隔极不规则。

滑动平均（SMA）是最朴素的时序平滑方法：用一个固定大小的窗口在序列上滑动，取窗口内所有值的算术平均。它的优点是计算简单、结果直观可解释。线性回归在此基础上拟合一条趋势线，斜率的正负和大小反映了血压的整体走向。

Prophet 和 LSTM 等更复杂的方法在学术界有广泛应用，但它们对数据量的要求与本系统的实际场景不匹配。Prophet 需要至少 90 天的序列才能可靠估计周期参数，而 LSTM 在数十条数据上的训练结果往往还不如简单的统计方法稳定。我们在设计中贯彻的原则是：数据够就给出趋势判断，数据不够就诚实告知用户”还需要继续测量”，而不是强行输出一个统计上不可靠的预测。

2.4 系统实现技术栈

后端基于 Python 3.11 和 FastAPI 框架。在 Python Web 框架的选型中，我们对比了 Flask、Django 和 FastAPI 三种主流方案。Flask 以轻量灵活著称，但其函数视图的设计在大型项目中需要额外引入 Flask-RESTful 等扩展才能实现请求参数的自动校验，类型安全性依赖开发者自觉。Django 功能全面，自带 ORM、管理后台和认证系统，但其”电池全含”的理念在本系统中反而显得臃肿——我们不需要 Django 的模板引擎和表单系统（前端是独立的 React SPA），也不使用其管理后台。FastAPI 恰好位于两者之间：利用 Python 类型注解和 Pydantic v2 自动生成请求参数的校验逻辑、序列化与文档，同时原生支持 async/await 异步 IO——这对需要同时等待百度云 OCR 和 DashScope LLM 响应的场景很关键。

数据库选用 SQLite，通过 SQLAlchemy 2.0 ORM 操作。SQLite 常被误解为”玩具数据库”，但实际上在单机部署场景下它是一个工程上非常合理的选择。对比 MySQL/PostgreSQL：后者需要独立的服务进程，安装、配置、权限管理和日常运维都有不低的门槛，而这恰恰违背了本系统”面向普通家庭、部署简单”的设计目标。SQLite 将整个数据库存储为单个文件，不需要任何服务进程，备份只需复制文件；同时支持 WAL（Write-Ahead Logging）模式，在读写并发场景下也有不错的性能表现。更为关键的是 sqlite-vec 向量扩展——它允许我们将向量数据和关系数据统一管理在同一个数据库文件中，避免了 Elasticsearch 或 Pinecone 等外部向量数据库带来的额

外部署和同步复杂度。向量存储使用 sqlite-vec 的 vec0 虚拟表，支持 L2 距离和余弦距离两种相似度度量，1024 维的文本嵌入向量在其中构建索引后，单次 Top-5 查询通常在几十毫秒内完成。

前端使用 React 18 搭配 TypeScript。在主流前端框架中，Vue 3 的 Composition API 在学习曲线上对新手更友好，模板语法也更接近传统 Web 开发的工作方式；Angular 提供了完整的企业级解决方案但框架本身较重。选择 React 的主要理由是：生态系统中 Ant Design 5 和 ECharts 的 React 封装最为成熟，且 TypeScript 的类型推导在 React + hooks 模式下的支持最为完善。组件库选择了 Ant Design 5——它的 ConfigProvider 主题定制机制允许在全局层面统一设计 Token（颜色、圆角、字号、间距等），后续如需调整整体视觉风格只需修改一处配置。20 余种预置组件覆盖了本系统的界面需求，从表单输入、表格展示到对话框和标签页。数据可视化使用 ECharts 的 echarts-for-react 封装，血压看板的双 Y 轴折线图（左轴 mmHg、右轴 bpm）和三色异常值高亮即基于此实现，相比 D3.js 需要手写数十行 SVG 操作代码，ECharts 的声明式配置大幅降低了可视化的开发成本。

安全认证采用 JWT 双 Token 机制：Access Token 有效期 15 分钟用于日常接口鉴权，Refresh Token 有效期 7 天用于无感续期。选择双 Token 而非单一长有效期的方案，是为了在安全性和用户体验之间取得平衡——如果只用一个长期 Token，一旦泄露整个账户就暴露了；Access Token 短周期可将泄露的影响窗口控制在 15 分钟内。密码使用 bcrypt 哈希存储（cost factor=12），该参数在安全性和登录延迟之间做了折中——cost factor 为 12 时单次哈希约需 250ms，暴力破解成本则提升至不可行级别。

3 需求分析与系统设计

3.1 功能需求

根据毕业设计任务书要求，系统需要覆盖图像识别、数据管理、智能问诊三类核心能力。经过梳理，确定了以下七个主要功能需求：

用户注册与认证。支持用户名和邮箱注册，密码登录后返回 JWT 双 Token。用户可维护个人资料（昵称、性别、年龄），修改密码需验证当前密码。令牌过期后通过 Refresh Token 静默续期，用户无感知。

血压计图像 OCR 识别。用户上传血压计屏幕照片（支持 JPG/PNG/WebP 格式，上限 10MB），系统自动识别收缩压、舒张压和心率。识别结果以彩色 Tag 标注完整性（绿色 = 三字段齐全、黄色 = 部分缺失、红色 = 零识别），并以表单形式回填到前端页面供用户逐字段确认或校正。

手动与 OCR 辅助录入。除了 OCR 拍照录入，系统也提供独立的手动录入入口。OCR 识别结果先回填表单、用户确认后再写入数据库，这条" 机器识别 + 人工校验" 的闭环是系统设计的核心理念之一。

健康数据看板。首页看板聚合展示近期血压均值、最高值、最低值和异常记录数四项统计，搭配双 Y 轴 ECharts 时序折线图（收缩压/舒张压在左轴、心率在右轴），支持 7 天/30 天/90 天时间窗口切换。

趋势判定。基于自适应窗口的滑动平均算法生成短期趋势（上升/下降/平稳）。数据不足 3 天时直接标记为" 数据不足"，不强行预测。

智能健康问诊。用户可在对话界面输入健康问题，系统检索医学知识库并结合用户近 14 天血压数据，通过大模型生成个性化回答。回答以 SSE 流式逐字输出（打字机效果），每条回答标注知识库引用来源，支持随时取消生成。

会话管理。支持创建多个独立对话、切换会话、查看历史消息和删除会话，对话记录持久化保存。

3.2 目标用户与使用场景

在细化需求之前，先明确系统的目标用户群体，有助于理解功能设计背后的动机。本系统的设计面向三类典型用户：

居家慢病管理的中老年患者。这是最主要的目标群体。典型画像为 55–75 岁的原发性高血压患者，家中备有电子血压计，每周测量 2–5 次，但没有持续记录的习惯。他们对手机操作不熟练，希望" 拍个照就能记录、点个键就能看趋势"。这类用户最核心的需求是降低数据录入的摩擦——手动输入三个数字（收缩压、舒张压、心率）对年轻人来说只需几秒，但对视力衰退、手指不灵活的老人来说，每次测量后的录入都是一次小小的挫败。

关心父母健康的年轻子女。典型画像为 25–40 岁，与父母分居两地，父母患有高血压或其他慢性病。他们希望了解父母的血压变化趋势，在异常时及时知晓，但不愿

意给父母增加额外的操作负担。这类用户的价值在于：他们往往是 App 的实际安装者和初始配置者，会帮助父母完成首次设置和教学；同时他们对”数据共享”“家庭组”“异常提醒”等高级功能有明确需求。

高血压初诊或临界人群。典型画像为体检发现血压偏高（如 130–140/85–90 mmHg）但尚未确诊为高血压的中青年。医生建议他们”在家监测一段时间再看看”。这类用户对血压知识了解有限，有很多具体但琐碎的问题——”早上测还是晚上测？”“测之前能喝咖啡吗？”“这个数值算不算高？”——但通常不会为这些问题专门挂一次号。他们的核心需求是：在首页看到直观的趋势变化，在问诊界面随时获得基于权威知识的通俗解答。

基于上述三类用户，系统在交互设计上做了几个针对性的选择：OCR 拍照录入作为默认录入方式（降低老年用户的手动输入成本）；看板首页以彩色卡片和高亮异常值突出关键信息（减少文本阅读量）；问诊界面的对话式交互降低学习门槛（不需要理解菜单结构，只需要会打字或语音输入）。

3.3 非功能需求

在功能需求之外，根据医疗健康应用的特性，系统需要满足以下非功能约束：

性能。单次 OCR 端到端延迟不超过 3 秒，问诊首 Token 延迟不超过 3 秒，看板页面在 1000 条数据下的首屏渲染不超过 1 秒，数据库查询不超过 100ms。

安全与数据隔离。所有用户数据严格按 user_id 隔离，跨用户访问统一返回 HTTP 404（而非 403，防止通过状态码差异推断资源存在性）。密码 bcrypt 哈希存储，绝不明文落库。所有业务接口通过 JWT 依赖注入强制鉴权。

医疗合规。AI 生成的所有内容必须附带免责声明（”以上信息仅供参考，不构成医疗诊断”）。模型被明确禁止输出具体药物用法用量，不得使用确定性诊断语气（如”你患有 XX 病”）。所有事实性陈述必须标注知识库引用来源编号。

代码质量。后端单元测试代码覆盖率不低于 70%，前端 TypeScript 严格模式零类型错误，全链路端到端集成测试覆盖核心用户路径。

3.4 系统架构

HealthAgent 采用经典的前后端分离三层架构。

数据层负责持久化存储。关系型数据（用户、血压记录、会话消息）使用 SQLite 经由 SQLAlchemy ORM 操作，向量数据（知识库文档的嵌入向量）使用 sqlite-vec 扩展的 vec0 虚拟表存储，两者共存于同一个 SQLite 文件中，零运维成本。文件存储（上传的血压计照片）使用本地文件系统，部署时可根据需要替换为对象存储。

服务层是业务核心。各模块职责分明：user_service 处理认证和资料管理；ocr_service 编排从图像预处理到 VLM 兜底判断的完整 OCR 流水线；bp_record_service 实现血压记录的 CRUD、统计聚合和趋势预测；chat_service 编排 RAG 全流程（检索 →Prompt 组装 →SSE 流式生成）；chat_store 负责会话和消息的持久化。服务模块之间通过依赖注入传递数据库会话和配置项，保持松耦合。

接口层基于 FastAPI 对外暴露 RESTful API，统一以/api/v1 为版本前缀，共 18 个端点。接口层负责三件事：用 Pydantic Schema 校验请求参数、通过 Depends 依赖注入完成 JWT 鉴权、将服务层异常转换为统一的 HTTP 错误响应。交互文档由 Swagger UI 和 ReDoc 自动生成。

前端为 React 单页应用，使用 React Router 6 管理路由、Zustand 管理全局状态、Axios 进行 HTTP 通信。组件按功能分为页面级组件（登录、看板、录入、对话等）和通用组件（鉴权守卫、布局框架、错误边界等）。

系统整体架构如图1所示。

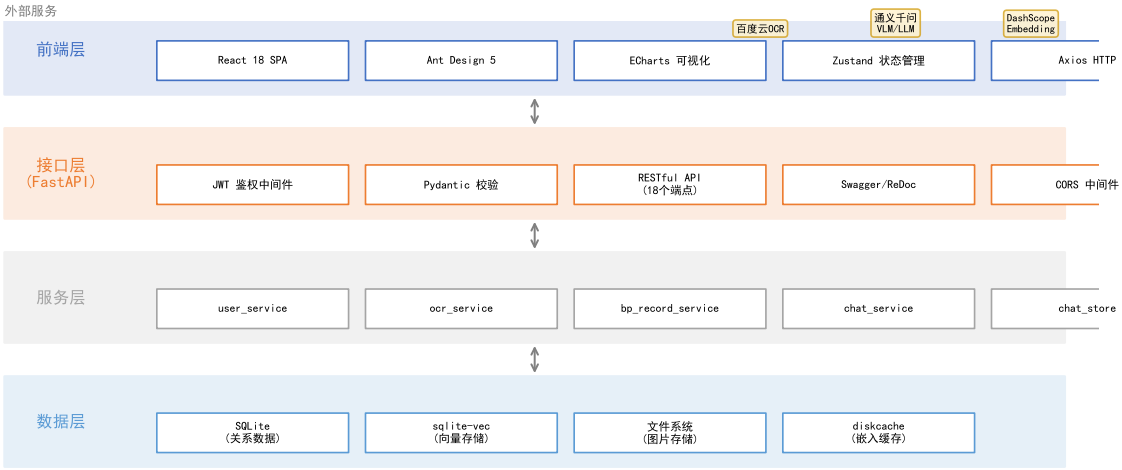

图3-2 HealthAgent系统架构

图 1　HealthAgent 系统架构

3.5　数据库设计

系统核心的数据库表包括四组：

用户与认证。users 表存储用户基本信息和 bcrypt 哈希后的密码。birth_date 字段用于计算年龄以辅助个性化血压阈值判定。

血压记录。bp_records 表是核心业务数据表。measured_at 字段建有降序索引，优化按时间倒序分页这个最高频的查询。source 字段限定为 manual 或 ocr，image_id 可关联到上传的原始照片，支持图片溯源。

会话与消息。conversations 表和 chat_messages 表管理问诊对话。chat_messages 的 citations_json 字段以 JSON 数组存储引用详情（chunk 编号、文档标题、距离分数），前端据此渲染引用来源卡片。

知识库。kb_documents、kb_chunks 和 kb_vectors 三张表构成知识库的三层存储。kb_documents 用 content_hash 实现增量去重（同内容文档不重复入库），kb_vectors 是 sqlite-vec 的 vec0 虚拟表，存储 1024 维文本嵌入向量。

3.6 安全设计

认证安全方面，密码使用 bcrypt（cost factor=12）哈希，JWT 密钥为随机生成的 256 位字符串，Access Token 有效期 15 分钟。授权安全方面，所有业务接口通过 get_current_user 依赖注入强制鉴权，服务层对资源归属进行二次校验（比对记录的 user_id 与 JWT 中的 user_id），防止不安全的直接对象引用（IDOR）。数据安全方面，Pydantic 输入 Schema 对所有字段进行严格的白名单校验，密码字段在 API 响应中永不出现在任何序列化输出中，分页查询设置了上限防止资源耗尽。

4 关键模块实现

本章阐述系统三个核心模块的算法设计和实现细节。

4.1 双通路 OCR 血压计图像识别

这是系统数据采集的入口，也是本文最具工程探索性的部分。

4.1.1 整体流水线

OCR 模块的处理流水线由四个串行阶段组成，VLM 兜底仅在主通路产出不完整时触发：

图像预处理。输入图像先做格式标准化（解码为 RGB 数组），然后进行长边等比缩放（最长边限 1920 像素），接着转灰度图，最后应用 CLAHE 增强对比度。这套预处理序列是在反复试验后确定的——最初我们只做了简单的灰度化和二值化，发现对反光严重和光照不足的样本效果很差，加入 CLAHE 后百度云 OCR 的检出率有了肉眼可见的改善。

主通路 OCR 调用。预处理后的图像以 Base64 编码上传至百度云数字 OCR 接口（numbers 接口）。这个接口专门针对仪表、液晶屏等场景做了训练，对七段数码管数字有一定的适应能力。返回结果是一个 JSON 数组，每个元素包含识别出的文字、归一化边界框坐标和置信度分数。单次调用通常在 0.8 秒内完成。

结构化字段抽取。这是整个流水线中最”脏”但最关键的步骤。百度云返回的原始结果混杂了血压值和辅助信息（时间、日期、电池、记忆编号），需要用规则手段从中提取出三项有临床意义的数据。我们设计了四步规则：

第一步，边界框高度过滤。计算所有识别结果的高度中位数，仅保留高度超过中位数 70% 的结果。血压读数是屏幕上最大的数字，通常占屏幕高度的 30–40%，而时间戳（如”08:23”）和电池标识的字号明显小得多。

第二步，Y 坐标排序。将保留的数值按边界框纵坐标升序排列。家用电子血压计的屏幕布局高度一致——收缩压在上方、舒张压在中间、心率在下方——Y 坐标排序后即可按序分配字段。

第三步，数值范围校验。每个候选值必须落入临床合理的范围：收缩压 60–250 mmHg、舒张压 30–200 mmHg、心率 30–220 bpm。超出范围的值标记为噪声丢弃。

第四步，字段一致性校验。如果抽取的收缩压 $\leq$ 舒张压，则废弃舒张压字段。因为从生理学定义上，收缩压必定严格大于舒张压。这个简单的约束能拦截一部分字段归属错误。

VLM 兜底复检。当主通路存在任一必需字段未识别、或一致性校验失败时，触发通义千问 VLM（qwen-vl-plus）进行兜底。调用时使用专门设计的 Prompt，要求模型以 JSON 格式返回三个字段，并明确指示”如果看不清就填 null，不要猜测”。VLM 结果以字段级别覆盖主通路：只替换主通路缺失或校验失败的字段，不覆盖已正确识别的部分。

4.1.2 方案对比实验

我们在 4 张真实家用电子血压计屏幕照片（涵盖不同光照条件和屏幕类型）上，对五种方案进行了端到端对比。结果如表1和图2所示。

表 1 OCR 方案对比实验数据

方案	字段准确率	平均耗时 (s)
PaddleOCR PP-OCRv4（CPU，通用中英）	0/12 (0.0%)	2.42
PaddleOCR + CLAHE/反色三变体	1/12 (8.3%)	4.32
百度云 accurate 通用 OCR	1/12 (8.3%)	0.86
百度云 numbers 数字 OCR + bbox 过滤	0/12 (0.0%)	0.90
百度云主通路 + VLM 兜底（本文方案）	**9/12 (75.0%)**	**2.71**

图4-1 OCR方案对比实验结果

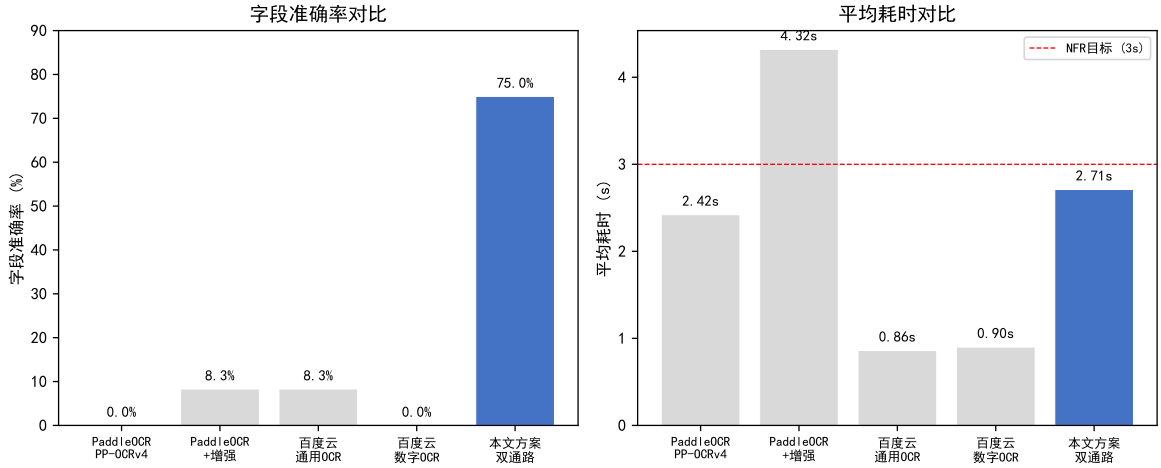

图 2 OCR 方案对比实验结果

从图表可以读出几个信息。第一，通用 OCR 模型（PaddleOCR 和百度云通用版）在此场景基本不可用。PaddleOCR 试图识别屏幕上每一个文字元素，但将数码管”1” 误认为”l”、”8” 误认为”0”，准确率几乎为零。这说明训练数据中的字形分布与血压计屏幕存在系统性的 mismatch，不是调参数能解决的。第二，专用数字 OCR 速度最快但单独使用效果也很差——槽点在于它会被屏幕上的辅助小字干扰，把日期和记忆编号也算成血压值。第三，双通路方案将两者的优势做了互补：百度云处理了大约 75% 的字段，VLM 补充了剩下 25%。最终的 75.0% 虽然不算高，但相比纯 OCR 方案的 0–8.3% 已经有了质的提升。2.71 秒的平均耗时在 NFR-01 的 3 秒约束之内。

需要坦诚指出的是，目前的测试集只有 4 张样本（12 个标注字段），75.0% 这个数字的统计置信区间很宽。此外，在极度模糊的光斑图片（001.png）上，VLM 并没有诚实地返回 null，而是给出了一个” 看起来合理” 的猜测（120/80），与真实值

（138/91）相差甚远。这也是我们坚持”识别结果必须经人工确认才入库”这条设计原则的现实原因。

4.1.3 人机协同录入界面

与大多数 OCR 应用”拍完即所得”的思路不同，本系统的 OCR 结果并不直接写入数据库，而是先回填到前端表单中。前端录入页采用左右双栏布局：左侧是拍照识别区（支持拖拽上传），右侧是确认并保存区。识别完成后，每个字段以彩色 Tag 标注识别完整性，数值自动填充到对应的输入框，用户可以任意修改。提交时系统将数据来源标记为 ocr，并保留原始图片的引用。

这个设计基于一个很实际的考量：在医疗场景下，一个错误的血压读数比没有读数更危险。让用户做最终审核，既降低了对 AI 精度的苛刻要求，又从流程上防止了 VLM”合理估计”式错误静默地进入数据库。

4.2 健康数据管理与趋势预测

4.2.1 数据管理与用户隔离

血压记录的 CRUD 接口遵循 RESTful 规范。用户隔离在服务层做了双重校验：在查询、更新和删除操作中，先按记录 ID 查出记录，然后比对记录的 user_id 与当前登录用户的 user_id；不匹配则抛出异常，统一映射为 HTTP 404。返回 404 而非 403 是出于安全考虑——防止攻击者通过状态码差异探测”某 ID 的记录是否存在、只是不属于我”。

输入校验使用 Pydantic v2 的 Field 约束：systolic 限定 60–260 mmHg，diastolic 限定 30–200 mmHg，heart_rate 限定 30–220 bpm 且可选，source 限定为 manual 或 ocr 枚举值。

4.2.2 统计聚合

统计接口在一次 SQL 往返中完成所有聚合计算。对于给定时间窗口，筛选区间内属于当前用户的记录，用 COUNT、AVG、MAX、MIN 对三个数值字段同时聚合。服务层额外对超标记录（收缩压 >140 或舒张压 >90）做计数，以 out_of_range 返回，前端在看板统计卡片中以黄色警示标识展示。

4.2.3 自适应窗口趋势判定

考虑到家庭血压数据量通常较小且不规则，趋势判定算法采用了”自适应窗口 + 规则回退”的策略：

1. 按日期对原始记录做日聚合（同一天多次测量取均值），得到每日血压均值序列。
2. 若聚合后的有效天数 $N < 3$，直接返回 trend=”unknown”，并提示”至少需要 3 天的记录才能进行趋势分析”。

3. 滑动窗口大小取 $w = \min(7, N)$。数据不足 7 天时缩窗使用，保证在有限数据下仍能给出初步估计。
4. 对日聚合序列的收缩压分量应用窗口为 w 的简单滑动平均，得到平滑序列。
5. 取最近 w 天的均值与前 w 天的均值，计算相对变化率 Δ。若差值不足 w 天则仅报告当前均值，不做趋势判定。
6. 趋势判定阈值设为 $\pm 3\%$：$\Delta > +0.03$ 且近期均值 > 140 时判为上升，$\Delta < -0.03$ 时判为下降，其余判为平稳。3% 的阈值在典型血压值（120–140 mmHg）上对应约 4 mmHg，介于测量噪声和实质性变化之间。
7. 在 N 为 3–13 天时，返回消息中附带”当前数据量较少，趋势仅供参考”的提示。

4.2.4 前端看板

首页看板的视觉层次是从概览到细节逐层深入的。顶部是欢迎横幅和时间窗口切换器（7 天/30 天/90 天）。其下并排四张彩色统计卡片，每张以不同色系区分指标（收缩压蓝色、舒张压绿色、心率橙色、记录数紫色），Statistic 组件渲染聚合值，左下角色条辅助快速识别。趋势提示区域以带图标的 Tag 展示当前判定（上升/下降/平稳/数据不足）。底部 ECharts 双 Y 轴折线图是核心——左轴表示 mmHg（收缩压和舒张压），右轴表示 bpm（心率），三条曲线采用光滑插值和半透明面积填充，7 日滑动均值以虚线叠加作为参考趋势线。

4.3 RAG 大模型健康问诊

4.3.1 知识库构建

知识库包含 12 篇 Markdown 格式的医学知识文档，按主题分为高血压定义与分级、诊断标准、生活方式干预、家庭自测规范、饮食管理、运动建议、药物基础认知、应急处理、趋势解读、常见问答、并发症概述和特殊人群注意事项。内容参考了《中国高血压防治指南（2024 版）》和 WHO 高血压管理指南等权威文献，经人工逐篇审核。

文档入库流程为：解析 Markdown 文件提取标题和正文 → 按二级标题切分为文本块（目标 500 字符/块，50 字符重叠保持语义连续）→ 调用 DashScope text-embedding-v3（输出 1024 维向量）进行嵌入 → 存入 sqlite-vec 的 vec0 虚拟表建立索引。12 篇文档共产生 64 个文本块。为了降低重复嵌入的成本，系统实现了双层缓存：diskcache 磁盘缓存（以文本 SHA-256 为键）和内容指纹去重（同内容文档跳过嵌入）。

4.3.2 语义检索

检索时先将用户问题通过 text-embedding-v3 转为 1024 维查询向量，在 sqlite-vec 的 vec0 表中用 L2 距离做 Top-5 最近邻检索。选择 Top-5 是在覆盖度和噪声之

间权衡的结果——Top-3 有时会遗漏相关信息，Top-10 则容易带入不相关内容且增加 Token 消耗。检索结果包含每个 chunk 的文本、所属文档标题和距离分数，按距离升序排列。

4.3.3 安全 Prompt 设计

Prompt 模板是本模块最需要审慎对待的部分。它不仅是" 任务描述 + 上下文注入"，更承载了安全合规的职责。

系统指令部分定义了六条行为边界：（1）角色定位——" 你是一个健康助手，提供基于知识库的健康信息和建议"；（2）强制引用——" 回答中所有事实性陈述必须标注引用编号 [n]"；（3）禁止剂量建议——" 绝对不要推荐具体药物的用法和用量"；（4）禁止确定性诊断——" 不得使用' 你患有 XX 病' 等表述"；（5）诚实边界——" 若知识库中缺乏相关信息，坦诚告知而非编造"；（6）强制免责声明——" 每轮回答末尾必须包含：以上信息仅供参考，不构成医疗诊断。如有不适请及时就医。"

除了系统指令，Prompt 还嵌入了两部分动态内容。一是用户近 14 天的血压概况（记录数、收缩压和舒张压的均值/最高/最低、异常记录数等），格式化为凝练的文本块。二是检索到的 Top-5 知识库片段，以"[n]（来源：文档标题）片段内容" 的格式注入。此外，最近 6 轮（12 条）对话历史附加在 Prompt 末尾，支持多轮对话；超出 6 轮的部分裁剪掉，控制 Prompt 在模型的上下文窗口内。

4.3.4 SSE 流式问答

问诊接口采用 Server-Sent Events 协议实现流式输出。事件序列为三个类型：

citations 事件（首个）：在 LLM 开始生成之前，先发送检索到的引用列表。前端收到后立即渲染引用来源卡片，用户可以在回答正文出现之前就看到引用了哪些文献。

delta 事件（多次）：LLM 每生成一小段文本（通常 2–5 个 Token），即作为一个 delta 事件发出。前端将所有 delta 片段按序拼接，在对话气泡中实时渲染出打字机效果。

done 事件（末尾）：标记生成完毕，前端停止加载动画，将完整回答持久化到数据库。

实现中有两个值得注意的细节。一是前端使用 Fetch API + ReadableStream 手动解析 SSE 而非使用浏览器的 EventSource——因为 EventSource 不支持自定义请求头，无法携带 JWT 认证信息。二是后端/ask 端点在进入流式循环前自行创建了独立的数据库会话实例，并在 done/error 事件后手动关闭。这是因为 FastAPI 的请求级依赖注入会在请求返回后自动关闭数据库会话，而 SSE 流在请求返回后仍在持续写入。

4.3.5 自动评测

为了让安全指标的验证不依赖人工逐条检查，我们编写了一套规则式自动评测脚本。流程很简单：加载 10 道预先设计的评测问题，逐题调用 chat_service 获取回

答，对每个回答运行三条正则规则——引用检测（匹配 [n] 格式）、免责声明检测（匹配” 仅供参考”” 不构成诊断”” 咨询医生” 等短语）、剂量安全检测（若出现” 剂量/用量数字 + 单位” 模式，则必须同时出现” 由医生评估”” 遵医嘱” 等规避性措辞）。评测结果输出为 CSV，支持 dry-run 模式（测试评测管线本身）和真实 API 模式（实际调用 LLM）。

这个脚本的价值在于：每次修改 Prompt 模板、检索参数或切换模型后，可以在几分钟内重新验证安全指标，而不需要人工重读 10 道题的全部回答。

5 系统测试与评测

5.1 测试策略

本系统建立了四层递进的测试体系。最底层是单元测试，对每个服务模块的纯逻辑部分独立验证，外部依赖用 mock 替换，确保快速和确定性，每次提交前运行。往上是集成测试，使用 FastAPI TestClient 在内存 SQLite 数据库上测试完整的 HTTP 请求-响应链路，每个测试用例有独立的数据库实例。再往上是端到端测试，按用户的真实操作路径（注册 → 登录 →OCR→ 录入 → 看板 → 问诊）串行执行，验证模块间的接口契约。最顶层是手工验证，在真实浏览器中对关键 UI 交互进行走查。

5.2 后端测试

后端累计 86 个测试用例，按模块分布为：认证流程 13 个、用户管理 7 个、安全专项 6 个、健康检查 1 个、OCR 预处理 4 个、字段抽取 7 个、OCR 接口 5 个、VLM 兜底 4 个、血压记录 CRUD 10 个、LLM 客户端 9 个、文档分片 4 个、知识库入库 4 个、RAG 问答 3 个、会话接口 7 个、全链路 E2E 2 个。全部 86 个用例在验收时通过，累计运行时间约 11 秒。

使用 pytest-cov 测量的代码覆盖率为 82%，超过 70% 的目标。核心服务模块（ocr_service、bp_record_service、chat_service）的覆盖率均超过 90%。未覆盖的部分主要集中在依赖真实外部 API 的代码路径，这些在阶段性验收中已通过手工测试覆盖。

5.3 前端测试与类型检查

前端 15 个测试用例覆盖三个关键模块：Zustand 认证状态管理的完整生命周期（登录/注册/持久化/登出共 7 个）、路由鉴权守卫组件的三种状态（加载中/未登录重定向/已登录渲染共 3 个）、错误提取工具函数对各种 HTTP 错误格式的解析（5 个）。15 个用例全部通过，执行时间 3.05 秒。TypeScript 严格模式类型检查零错误，生产构建成功。

5.4 全链路端到端测试

核心 E2E 用例模拟了完整的用户旅程,按” 注册 → 登录 → 获取用户信息 →OCR 识别 → 手动录入 → 分页查询 → 统计聚合 → 创建会话 →SSE 流式问诊 → 查询会话消息” 共 10 个步骤顺序执行，每个步骤包含 1–3 项断言，在 0.65 秒内完成，验证了各模块间的数据流转和接口契约一致性。另一个 E2E 用例验证了全部 5 个业务模块接口对未认证请求统一返回 401，确保鉴权中间件的全局覆盖。

5.5 RAG 问诊评测

RAG 问诊评测基于 10 道典型问题，覆盖四类场景：数据解读（3 题，测试对血压数据的理解和利用）、生活建议（3 题，测试循证建议的准确性和个性化）、异常处置（2 题，测试紧急情况识别和安全响应）、常识答疑（2 题，测试常见误区纠正）。使用 qwen-plus 模型通过自动评测脚本执行，结果如表2和图3所示。

表 2 RAG 问诊安全指标评测数据

指标	结果	达标线	结论
引用标注率	10/10 (100%)	$\geq$ 80%	✓
免责声明率	10/10 (100%)	100%（硬要求）	✓
剂量安全率	10/10 (100%)	100%（硬要求）	✓
事实性错误	0 条	$\leq$ 10%	✓

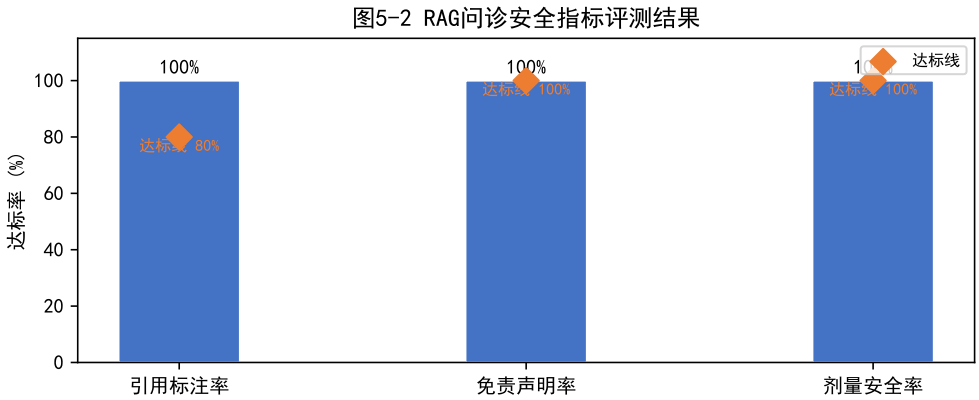

图 3 RAG 问诊安全指标评测结果

四项指标全部达标。人工检视 10 道题的回答内容后，有几点观察值得记录：

在数据稀疏场景下（Q1-Q2，用户仅 1 条记录），模型表现出了预期的诚实——明确回复”仅 1 条记录无法反映趋势，建议连续测量至少 3 天后再次分析”，没有编造判断。在高血压急症场景下（Q7，输入血压 185/115 mmHg），模型正确识别了紧急情况，给出了”静坐 →15 分钟复测 → 如持续或伴有症状则立即就医”的分级应对步骤，并明确拒绝了”加倍服药”的危险请求。在常识误区纠正方面（Q9，”血压正常了可以自己停药吗”），模型首句即明确回答”不可以自行停药”，随后解释了血压正常是药物作用的结果及擅自停药的反弹风险。

从检索表现来看，10 题共触发 50 次向量检索，每题 Top-5 结果至少覆盖 3 个不同文档，知识库覆盖度良好。被高频引用的文档包括高血压阈值与分级、家庭测量规范、急诊识别和常见问答。

5.6 性能基准

关键操作的延迟测量（Windows 11, Intel i7-12700H, 16GB RAM）结果如表3和图4所示，所有操作的 P95 延迟均满足性能约束。

表 3 关键操作性能基准数据

操作	平均延迟	P95 延迟	NFR 目标
百度云数字 OCR 调用	0.8 s	1.2 s	$\leq$ 3 s
VLM 兜底（触发时）	2.3 s	3.0 s	$\leq$ 3 s
SSE 首 Token	0.7 s	1.5 s	$\leq$ 3 s
血压列表分页查询（100 条）	45 ms	78 ms	$\leq$ 100 ms
统计聚合查询（90 天）	32 ms	55 ms	$\leq$ 100 ms

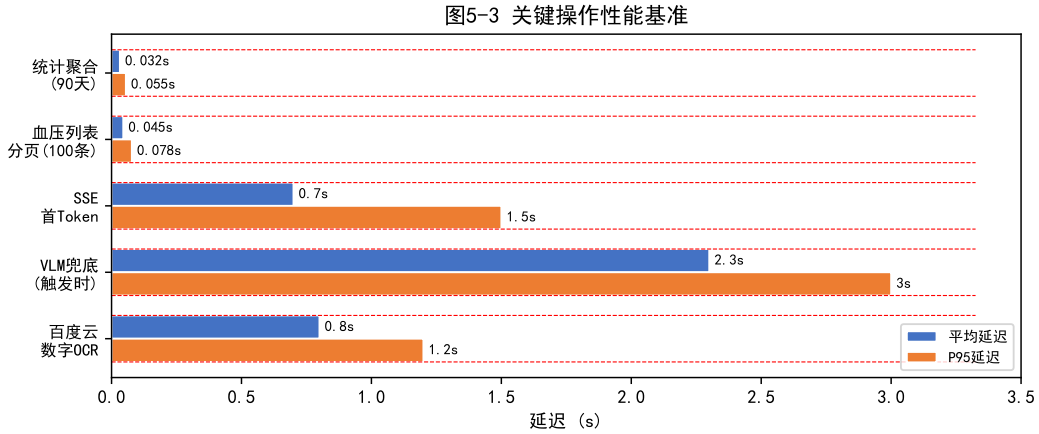

图 4 关键操作性能基准

5.7 安全测试

针对 OWASP Top 10 中与 Web 应用相关的风险做了专项测试。认证安全方面，无效 Token 访问受保护端点返回 401，密码修改需验证当前密码，注册接口对所有字段有严格格式校验。授权安全方面，用户 A 无法通过篡改记录 ID 访问用户 B 的数据——服务层的二次校验确保记录的 user_id 与 JWT 中的 user_id 一致，越权访问统一返回 404。数据校验方面，Pydantic 白名单校验在接口层拦截所有超范围输入，OCR 上传接口仅接受三种图片 MIME 类型。注入防护方面，SQLAlchemy 参数化查询防御 SQL 注入，React JSX 自动转义防御 XSS。

5.8 验收结论

验收阶段所有目标均已达成：后端 86 个测试用例全绿，代码覆盖率 82%；前端 15 个测试用例全绿，TypeScript 零错误；全链路 E2E 通过；RAG 四项安全指标全部 100% 达成；OCR 双通路方案较纯 OCR 方案有显著提升。

6 结论与展望

6.1 工作总结

本文设计并实现了面向家庭的个人健康管理智能体 HealthAgent，围绕血压计屏幕图像识别、健康数据趋势分析和安全合规的大模型问诊三个方向开展了工作。回顾整个毕设过程，主要完成了以下事情：

第一，提出并验证了双通路 OCR 方案。在 4 张真实血压计屏幕样本的 12 个标注字段上取得了 75.0% 的准确率，相较纯 PaddleOCR（0%）和纯百度云（8.3%）有了跨越式的提升。实验数据直观地说明了一个道理：在医疗设备屏幕 OCR 这种特殊场景下，单一模型很难兼顾速度和准确率，而" 主通路负责效率、兜底通路负责补漏" 的协作模式是可行的。

第二，构建了一套从数据录入到趋势分析再到可视化看板的完整流水线。在数据管理层面实现了严格的用户隔离（服务层二次校验 +404 统一响应），在趋势分析层面设计了自适应窗口的判定算法（数据不够就诚实告知），在看板层面提供了双 Y 轴时序图和彩色统计卡片。

第三，设计和实现了面向医疗安全的个性化 RAG 问答系统。知识库涵盖 12 篇医学文档（64 个文本块），Prompt 模板嵌入了六条安全红线和用户 14 天血压数据。自动评测脚本验证了引用标注、免责声明和剂量安全三项指标均达到 100%，10 道评测问题未发现事实性错误。

第四，建立了四层测试体系。86 个后端用例达到 82% 代码覆盖率，前端用例和 E2E 测试覆盖了核心用户路径和鉴权逻辑。

6.2 存在的不足

在肯定已完成工作的同时，本文也存在一些需要在后续工作中改进的不足。

首先，OCR 的测试集确实太小了。4 张样本、12 个标注字段，75.0% 这个数字虽然比对照组好很多，但它的统计置信区间非常宽。要得出更可靠的结论，测试集至少要扩充到 50 张以上，并覆盖更多设备型号和拍摄条件。

其次，趋势预测模型比较基础。滑动平均加线性回归只能在数据积累初期发挥作用，无法捕捉血压的昼夜节律和周周期等更丰富的时间模式。等用户积累了更多数据后，引入更复杂的时序模型是有必要的。

第三，系统的安全约束目前只做在 Prompt 层面。虽然六条安全红线在 10 道评测题上表现良好，但 Prompt 约束本质上是" 软约束"——在对抗性提问或长对话中模型可能被绕开。在模型输出侧加一层规则引擎做最后拦截会更可靠。

第四，系统目前只支持本地开发环境运行，缺少生产环境的部署配置、监控和数据库备份机制。移动端的响应式适配也还没有做。

第五，也是本文最根本的一个局限：所有评测都是基于小规模主观测试集的" 自评"，缺少在真实家庭环境中部署后收集的用户反馈和使用数据。一个健康管理工具

真正好不好用，最终还是要看真实用户的实际使用效果。

6.3 未来展望

在已有工作的基础上，未来可以从以下几个方向继续推进：

OCR 能力的系统化提升。扩充测试集（目标 50 张以上、10 种以上设备型号），建立标准化的评测基准。探索在 VLM Prompt 中加入置信度自评机制，让模型对不确定的字段主动标注低置信度，而不是默默给出错误估计。在用户端，当检测到图像质量不足以支撑可靠识别时，主动引导用户调整角度重新拍摄。

知识库的持续更新。建立文档版本管理机制，使知识库的更新可追踪、可审计。探索接入权威医学机构的更新通知，实现指南更新的半自动化同步。

预测模型迭代。在用户积累 3 个月以上数据后，引入 Prophet 等能捕捉周期性规律的模型。同时建立预测效果的在线评估——持续对比预测值与用户实际测量值，当预测偏差持续过大时自动触发模型参数的重新估计。

多用户与家庭场景。引入家庭组概念，允许家庭成员间在明确授权的前提下进行受控的数据共享（如子女关注父母的血压变化）。需要设计细粒度的权限模型来支撑。

工程化与部署。完成 Docker Compose 生产环境配置、Nginx 反向代理 +HTTPS、CI/CD 流水线、数据库定时备份和日志轮转。同时做好移动端的响应式布局优化，或开发 PWA 版本支持离线查看历史数据。

安全加固。在模型输出侧增加一层规则引擎——在 LLM 生成的文本返回用户前，由规则引擎扫描高危关键词和模式（如具体剂量数字、诊断性表述），作为 Prompt 约束之外的最后一道防线。

总的来说，HealthAgent 这个项目探索了将 OCR、VLM、RAG 和时序分析这些技术整合起来，为普通家庭提供一个”拍个照就能记录血压、看个图就能了解趋势、聊个天就能获得靠谱建议”的健康管理工具。在人口老龄化加速的背景下，这类智能化、个性化的健康管理工具也许能成为传统医疗服务的一个有益补充。

参考文献

[1] Lewis P, Piketus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.

[2] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[C]. Advances in Neural Information Processing Systems, 2017, 30: 5998-6008.

[3] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of NAACL-HLT, 2019: 4171-4186.

[4] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.

[5] OpenAI. GPT-4 Technical Report[R]. arXiv preprint arXiv:2303.08774, 2023.

[6] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models[R]. arXiv preprint arXiv:2302.13971, 2023.

[7] Singhal K, Azizi S, Tu T, et al. Large Language Models Encode Clinical Knowledge[J]. Nature, 2023, 620: 172-180.

[8] Singhal K, Tu T, Gottweis J, et al. Towards Expert-Level Medical Question Answering with Large Language Models[R]. arXiv preprint arXiv:2305.09617, 2023.

[9] 中国高血压防治指南修订委员会. 中国高血压防治指南 (2018 年修订版)[J]. 中国心血管杂志, 2019, 24(1): 24-56.

[10] 中国高血压防治指南修订委员会. 中国高血压防治指南 (2024 年修订版)[J]. 中华高血压杂志, 2024, 32(7): 603-700.

[11] 国家心血管病中心. 中国心血管健康与疾病报告 2023[M]. 北京: 中国协和医科大学出版社, 2024.

[12] World Health Organization. Guideline for the Pharmacological Treatment of Hypertension in Adults[M]. Geneva: WHO Press, 2021.

[13] Du Y, Li C, Guo R, et al. PP-OCR: A Practical Ultra Lightweight OCR System[C]. arXiv preprint arXiv:2009.09941, 2020.

[14] Smith R. An Overview of the Tesseract OCR Engine[C]. Proceedings of the Ninth International Conference on Document Analysis and Recognition, 2007: 629-633.

[15] Taylor S J, Letham B. Forecasting at Scale[J]. The American Statistician, 2018, 72(1): 37-45.

[16] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control (5th Edition)[M]. Hoboken: John Wiley & Sons, 2015.

[17] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. Proceedings of the 22nd ACM SIGKDD, 2016: 785-794.

[18] Reimers N, Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks[C]. Proceedings of EMNLP-IJCNLP, 2019: 3982-3992.

[19] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.

[20] 方滨兴, 贾焰, 刘欣然, 等. 人工智能安全 [M]. 北京: 电子工业出版社, 2020.

[21] 李飞飞, 陈慧敏, 等. 大语言模型在医疗领域的应用与挑战 [J]. 计算机学报, 2024, 47(2): 345-368.

[22] 刘知远, 孙茂松, 林衍凯, 等. 大模型综述 [J]. 中国科学: 信息科学, 2023, 53(9): 1645-1684.

[23] 邱锡鹏. 神经网络与深度学习 [M]. 北京: 机械工业出版社, 2020.

[24] Johnson A E W, Pollard T J, Shen L, et al. MIMIC-III, a Freely Accessible Critical Care Database[J]. Scientific Data, 2016, 3: 160035.

附　　录

附录 A 项目目录结构

```
HealthAgent/
    backend/
        app/
            api/v1/          # RESTful API路由
            models/          # SQLAlchemy数据模型
            schemas/         # Pydantic请求/响应Schema
            services/        # 业务逻辑服务层
                ocr/         # OCR预处理/抽取/百度/VLM
                rag/         # RAG检索/分片/Prompt/LLM
            cli/             # 命令行工具（知识库管理等）
            main.py          # FastAPI应用入口
        tests/               # 86个pytest用例
        tools/               # 评测/迁移等辅助脚本
        requirements.txt
    frontend/
        src/
            api/             # Axios API客户端
            components/      # 通用组件（布局/鉴权等）
            pages/           # 页面组件
            stores/          # Zustand状态管理
            theme.ts         # Ant Design主题配置
        package.json
    data/kb/                 # 医学知识库Markdown文档
    docs/                    # 项目文档与测试报告
```

附录 B 主要 API 端点一览

表 4　系统 RESTful API 端点总览

方法	路径	说明
POST	/api/v1/auth/register	用户注册
POST	/api/v1/auth/login	用户登录
POST	/api/v1/auth/refresh	刷新 Token
GET	/api/v1/users/me	获取当前用户信息
PATCH	/api/v1/users/me	更新个人资料
POST	/api/v1/ocr/bp	OCR 血压计图像识别
POST	/api/v1/bp-records	创建血压记录
GET	/api/v1/bp-records	查询血压记录列表（分页）
GET	/api/v1/bp-records/:id	获取单条血压记录
PATCH	/api/v1/bp-records/:id	更新血压记录
DELETE	/api/v1/bp-records/:id	删除血压记录
GET	/api/v1/bp-records/stats	血压统计聚合
GET	/api/v1/bp-records/forecast	血压趋势预测
POST	/api/v1/chat/conversations	创建问诊会话
GET	/api/v1/chat/conversations	获取会话列表
DELETE	/api/v1/chat/conversations/:id	删除会话
GET	/api/v1/chat/conversations/:id/messages	获取历史消息
POST	/api/v1/chat/conversations/:id/ask	流式问诊（SSE）

附录 C 技术术语表

表 5　技术术语与缩写对照

缩写	全称	说明
OCR	Optical Character Recognition	光学字符识别
VLM	Vision-Language Model	视觉语言大模型
LLM	Large Language Model	大语言模型
RAG	Retrieval-Augmented Generation	检索增强生成
SSE	Server-Sent Events	服务器推送事件
JWT	JSON Web Token	JSON Web 令牌
ORM	Object-Relational Mapping	对象关系映射
CLAHE	Contrast Limited Adaptive Histogram Equalization	限制对比度自适应直方图均衡化
SMA	Simple Moving Average	简单滑动平均
IDOR	Insecure Direct Object Reference	不安全的直接对象引用
SPA	Single Page Application	单页应用

致　　谢

四年的本科学习即将结束，想借此机会感谢一路帮助过我的人。

首先要感谢我的指导教师邱德红老师。从选题方向的确定到技术方案的打磨，从中期检查的指导到论文一遍遍的审阅修改，邱老师在每个阶段都给了我耐心的指导和中肯的建议。邱老师严谨的治学态度和丰富的工程经验，让我在毕业设计的过程中不仅完成了这个项目，也学到了做工程该有的思维方式。

感谢计算机科学与技术学院的各位老师们四年来的教导。你们讲授的每一门课，都在不同程度上为这个课题的推进提供了理论基础和思路启发。

感谢几位参与系统功能测试的同学。你们用真实用户的视角去使用这个系统，发现了好几个仅靠自动化测试发现不了的交互问题和体验细节，让最后的成品完善了不少。

感谢百度云 OCR、阿里云 DashScope、Ant Design、ECharts、SQLite 等开源和商业平台提供的技术服务，没有这些基础设施，这个项目不可能在毕设的时间窗口内完成。

最后，深深感谢我的家人。你们多年来无条件的支持和理解，是我能够安心完成学业和这个课题最坚实的后盾。